

Arquitetura de detecção contínua

Sistema híbrido de regras, agente investigador e validação humana · Proposta para o parque da Ondaluz e outros provedores

A proposta parte de um padrão já aplicado em uma plataforma de dispositivos IoT: o sistema identifica desvios em escala, um agente consulta dados relacionados e transforma o sinal em uma análise contextual, e o operador humano conserva a decisão sobre qualquer impacto no cliente ou na rede.

Princípio central

O modelo de linguagem **não processa cada Inform**. A camada determinística recebe toda a telemetria; o agente atua como investigador sobre candidatos e recortes agregados. Assim, custo, latência ou indisponibilidade do agente não interrompem a ingestão.

Responsabilidades separadas

1. Sistema determinístico

Processa o volume, normaliza unidades, calcula métricas e identifica sinais objetivos.

2. Agente de análise

Consulta o MCP, correlaciona evidências e prepara uma conclusão estruturada.

3. Operador humano

Confirma, corrige ou descarta antes de qualquer ação operacional.

Escala de partida

300 mil	3,6 milhões	~42/s	20x
CPEs	Informs por dia	média nominal	margem inicial de pico

O desafio real são rajadas de reconexão, diferentes fabricantes, eventos atrasados e a necessidade de converter milhares de sinais em poucos casos acionáveis.


Metas iniciais de operação

Indicador	Meta
Confirmação do Inform	menos de 500 ms no p99
Inform disponível para regras	menos de 60 s no p99
Investigação após gatilho crítico	menos de 5 min
Eventos válidos processados	pelo menos 99,9%
Ações sem validação humana	zero

As metas serão validadas com o NOC e ajustadas após testes de carga, custo e qualidade dos alertas.

Visão da solução híbrida

O desenho separa o plano que processa o parque inteiro do plano que conduz investigações delimitadas. Os dois caminhos continuam úteis mesmo quando o outro está temporariamente indisponível.



Camada	Responsabilidade	Garantia
Plano de dados	Recebe Inform, normaliza unidades, preserva histórico e calcula agregados.	Continua operando sem o agente.
Plano de investigação	Recebe pergunta delimitada, executa o agente e produz uma conclusão para revisão.	Não bloqueia o ACS nem altera dispositivos.
Orquestrador	Controla agenda, fila, orçamento, validação e persistência do ticket.	O modelo não recebe escrita direta.
MCP	Expõe clientes, inventário, telemetria, diagnósticos, chamados e operação.	Somente leitura e escopo por provedor.

Por que o barramento continua necessário?

Kafka não é usado porque 42 eventos/s sejam altos. Ele absorve rajadas, desacopla o ACS, permite replay e converte indisponibilidade de consumidores em lag observável, não em perda de telemetria.

Os dois caminhos de análise

1. Caminho reativo

Um sinal objetivo dispara a investigação.

- FEC cresce em várias CPEs da mesma PON.
- Memória e boots pioram após rollout.
- Rx permanece fora da faixa.
- Plano excede a capacidade LAN.
- Inform deixa de chegar além da tolerância.

2. Caminho proativo

Uma agenda ou um operador inicia a investigação.

- A cada 15 min: degradação compartilhada.
- A cada hora: versões com rollout recente.
- Diário: plano versus capacidade.
- Semanal: chamados por região/modelo.
- Sob demanda durante um incidente.

Como o gatilho é formulado

A regra não precisa afirmar a causa. Ela cria uma pergunta delimitada, por exemplo: **investigue o aumento de FEC na OLT-2/PON 1/7 nos últimos 30 minutos**. O agente recebe escopo, janela e evidências iniciais; então consulta baseline, topologia, firmware, chamados e diagnósticos.

Agenda recorrente

Frequência	Objetivo	Recorte obrigatório
15 minutos	Degradação óptica compartilhada	provedor + OLT/PON + janela
1 hora	Comportamento após rollout	modelo + firmware + controle
Diária	Incompatibilidade comercial	plano + modelo + revisão
Semanal	Tendências ainda sem regra	região + fabricante + chamados
Sob demanda	Pergunta de um operador	hipótese + escopo + prazo

Agendamento e execução são responsabilidades diferentes

O cron pertence à aplicação: ele cria a tarefa, registra estado, tentativas e prazo. A execução do modelo pode rodar de forma assíncrona, mas o modo background não substitui o scheduler.

Critério de uso

O caminho reativo reduz o tempo até a percepção do NOC. O caminho proativo procura padrões que ainda não possuem um threshold conhecido. Ambos usam o mesmo MCP, limites e contrato de saída.

Do Inform até a validação humana



Etapa	O que acontece	Controle importante
1. Recepção	Gateway adiciona provedor, evento, serial, event_time, received_at e schema.	Responde ao ACS após gravar no barramento.
2. Normalização	Adaptadores convertem nomes e unidades por fabricante/modelo/firmware.	Evento incompatível vai para quarentena.
3. Enriquecimento	Associa plano, firmware e caminho OLT > PON > CTO válidos no momento.	Não usa apenas o inventário atual.
4. Agregação	Cria janelas por CPE, firmware, CTO, PON, OLT, região e provedor.	Bruto permanece reprocessável.
5. Gatilho	Regra cria solicitação idempotente com escopo, janela e evidências.	Não afirma uma causa sem investigação.
6. Investigação	Agente começa por agregados e consulta detalhes pelo MCP quando necessário.	Limites de tempo, tokens e ferramentas.
7. Conclusão	Retorna categoria, alcance, evidências, confiança, impacto e próxima ação.	Saída estruturada e versionada.
8. Validação	Orquestrador confirma schema, evidências, provedor e duplicidade.	Agente não escreve no banco.
9. Decisão	Operador confirma, corrige ou descarta; só então existe incidente.	Nenhuma ação automática no parque.

Semântica do Inform

Inform é a mensagem TR-069 enviada pela CPE ao ACS em eventos como boot, mudança de parâmetro ou comunicação periódica. Ela identifica o equipamento, o motivo do contato e os parâmetros disponíveis naquele envio. Ausência de Inform é inferida por temporizador, porque não existe um evento de não recebimento.

Contrato do agente e controles MCP

A saída livre do modelo não controla o fluxo. O agente devolve um objeto versionado; o orquestrador valida os campos e as referências antes de criar o ticket.

```
{
  "analysisVersion": "1.0",
  "providerId": "ondaluz",
  "category": "optical_degradation",
  "scope": {"type": "pon", "olt": "OLT-2", "pon": "1/7"},
  "severity": "high",
  "confidence": 0.91,
  "affectedCpes": 60,
  "evidence": [{"source": "telemetry", "reference": "metric-window:..."}],
  "counterEvidence": [],
  "probableCause": "degradação em segmento óptico compartilhado",
  "recommendedAction": "inspecionar trecho comum antes de visitas",
  "requiresHumanReview": true
}
```

Confiança não basta

Para criar o ticket, o orquestrador exige evidências rastreáveis, escopo autorizado e ação pertencente à lista permitida. Se faltar informação, o resultado deve ser **inconclusivo**, nunca uma causa inventada.

MCP por domínio e somente leitura

Domínio	Exemplos de consulta	Limite
Clientes	identificador técnico, plano e status	sem PII quando desnecessária
Inventário	fabricante, revisão, firmware, OLT/PON/CTO	contexto temporal
Telemetria	agregados, baseline e detalhe por serial	paginação e janela obrigatórias
Diagnósticos	TR-143, LAN negociada e resultados	leitura e evidência rastreável
Chamados	categoria, tendência e resolução	texto tratado como dado não confiável
Operação	incidentes e visão consolidada	escopo por provedor

A autenticação informa a identidade do serviço e os provedores permitidos. A autorização é aplicada pelo servidor MCP, não pelo prompt. Um agente não amplia o próprio escopo enviando outro provider_id. Segredos ficam fora do prompt e dos logs.

Como o ticket é criado

Funcionalmente, o agente prepara o ticket. Tecnicamente, um serviço confiável do orquestrador grava o registro depois da validação. Reboot, rollback, configuração e ordem de serviço ficam fora das ferramentas automáticas.

Escala, custo e aplicação aos problemas

O agente não recebe 3,6 milhões de eventos por dia. O volume é reduzido antes de qualquer chamada ao modelo.

1. Absorver

Kafka recebe picos e mantém replay sem bloquear o ACS.

2. Resumir

Store temporal e agregados transformam eventos em janelas.

3. Correlacionar

Sinais equivalentes viram uma investigação por escopo.

4. Investigar

Agente aprofunda apenas grupos suspeitos e evidências.

A chave **provedor + tipo de problema + escopo + janela** transforma, por exemplo, 60 sinais da mesma PON em uma única investigação. Jobs registram checkpoint, cotas por provedor e prioridade; cache evita repetir consultas na mesma execução.

Aplicação aos problemas encontrados

Problema	Gatilho determinístico	Investigação do agente	Entrega ao humano
Degradação óptica	FEC, Rx ou ausência desviam do baseline de PON/CTO.	Cruza topologia, alcance, chamados e outras PONs.	Trecho provável, afetados e recomendação de inspeção.
Regressão de firmware	Memória e boots pioram após rollout.	Compara versão nova, controle, período anterior e regiões.	Evidência para congelar rollout e executar canário.
Plano incompatível	Plano excede velocidade LAN negociada.	Confirma revisão, capacidade, upgrade e diagnósticos.	Fila priorizada e bloqueio preventivo.
Falha individual	Limite persiste sem cluster compartilhado.	Elimina incidentes coletivos e revisa o histórico da CPE.	Roteiro N1 ou visita direcionada.


Onde está o valor do agente

O agente acrescenta correlação, exploração orientada por hipótese e explicação. Contas, unidades, thresholds e limites básicos continuam determinísticos, versionados e testáveis.

Controles de custo

- Fila com concorrência e orçamento por provedor.
- Agregados primeiro; detalhe por CPE somente quando necessário.
- Tempo, tokens, número de ferramentas e volume retornado limitados por execução.
- Jobs exploratórios nunca atrasam investigações críticas.
- Deduplicação e checkpoint evitam reanalisar o mesmo período.

Ciclo de vida e decisões arquiteturais



Cada transição registra horário, ator, prompt e versões das regras, ferramentas consultadas, referências e decisão humana. Falsos positivos alimentam avaliações controladas; nunca alteram automaticamente a produção.

Decisões e alternativas descartadas

Decisão	Alternativa	Motivo
Regras + agente	apenas regras ou apenas agente	Regras escalam; o agente acrescenta correlação sem processar cada evento.
Gatilho + recorrência	somente thresholds	Jobs temáticos procuram padrões ainda sem regra conhecida.
MCP read-only	banco direto ou escrita	Reduz privilégio e separa investigação de ação operacional.
Orquestrador grava	agente escreve	Valida schema, escopo, evidências e duplicidade antes de persistir.
Saída estruturada	texto livre	Campos obrigatórios são verificáveis e não deixam prosa controlar o fluxo.
Agregados primeiro	todos os Informs no modelo	Reduz custo, latência, exposição de dados e contexto.
Um agente inicial	vários agentes	Mais simples de avaliar e auditar; especialização precisa provar valor.
Revisão humana	ação por confiança	Confiança do modelo não substitui autorização operacional.
At-least-once + idempotência	exactly-once ponta a ponta	Recuperação mais simples e idempotência ainda necessária nas integrações.
Baseline explicável	ML supervisionado imediato	Ainda faltam rótulos causais confiáveis para treino e avaliação.

Critério de segurança

Ação operacional permanece humana mesmo quando a análise tem confiança alta. Fibra exige inspeção; firmware exige canário controlado; incompatibilidade comercial exige validação de inventário e processo.

Relação com o protótipo e evolução

O protótipo já demonstra o plano de dados em lote, as regras explicáveis, as jornadas NOC/N1 e o MCP por domínio e somente leitura. PostgreSQL concentra telemetria, agregados e consultas para manter a entrega executável em uma máquina.

Já entregue	Próxima evolução
COPY streaming de CSV/GZIP e carga idempotente	ingestão contínua e barramento durável
Agregados diários e regras explicáveis	janelas incrementais e gatilhos em minutos
API NestJS e telas NOC/N1	tickets de revisão e feedback do operador
MCP de clientes, inventário, telemetria, diagnósticos, chamados e operação	orquestrador com agente e agenda recorrente
PostgreSQL local	store temporal + histórico bruto + PostgreSQL operacional

Sequência de evolução

Etapa	Entrega	Critério para avançar
1	Adicionar orquestrador sobre o MCP existente.	Autorização e auditoria verificadas.
2	Começar com investigação manual e um job diário.	Execuções estáveis e custo medido.
3	Criar conjunto de casos revisados por especialistas.	Baseline de precisão e falso positivo.
4	Medir tempo poupado, qualidade e cobertura.	Ganho demonstrado para NOC/N1.
5	Habilitar gatilhos e aumentar frequência gradualmente.	Canário sem tempestade de tickets.
6	Substituir lote por ingestão contínua.	Contrato das telas preservado.

Deliberadamente fora do escopo

- Reboot, rollback, alteração de configuração ou ordem de serviço automáticos.
- Implementação real do agente, scheduler, fila e conectores externos nesta entrega.
- Kafka, ClickHouse, object storage, Kubernetes, multi-região e disaster recovery implantados.
- Modelo, prompt, frequência e orçamento definitivos sem avaliação com casos reais.
- Adaptadores para todos os fabricantes e investigação individual de todas as CPEs.
- Fine-tuning, churn, clima/energia e aprendizado compartilhado entre provedores.
- Garantia de causa raiz sem confirmação operacional.

Direção final

O sistema encontra sinais; o agente transforma sinais em investigação compreensível; o humano conserva a decisão sobre qualquer impacto no cliente ou na rede.

Referências de implementação

OpenAI: MCP connections · Background mode · Safety in building agents. O conteúdo arquitetural permanece independente do fornecedor do modelo.